



**WYŻSZA SZKOŁA
INFORMATYKI i ZARZĄDZANIA**
z siedzibą w Rzeszowie

KOLEGIUM INFORMATYKI STOSOWANEJ

Kierunek: INFORMATYKA

Grupa: IN.ISP.028 A L1 2026 L

Vladyslav Vasylyv
Nr albumu studenta 72226, IN.ISP.028 A L1 2026 L

Laboratorium 5

Promotor: dr inż. Mariusz Wrzesień

Rzeszów 2026

0.1 Opis problemu

Celem zadania jest pogrupowanie zbioru danych **IRIS** za pomocą algorytmu k -średnich dla $k = 3$ oraz porównanie uzyskanych klastrów z oryginalną etykietą gatunku. Dodatkowo omówiono wady i zalety algorytmu.

Parametry dobrano zgodnie z numerem indeksu studenta **72226** (ostatnia cyfra = 6):

[noitemsep]

- usuwano co dziesiąty przypadek o numerze kończącym się na **6**: LP 6, 16, 26, ..., 146 (łącznie 15 przypadków),
- środki startowe: przypadki **47, 88, 129** (reguła $41+D, 82+D, 123+D$).

0.2 Badany zbiór danych

0.2.1 Opis

Zbiór *Iris* zawiera 150 próbek trzech gatunków irysów: *Iris-setosa*, *Iris-versicolor*, *Iris-virginica* – po 50 próbek każdego. Cztery atrybuty numeryczne opisują wymiary płatków i działek kielicha.

0.2.2 Przygotowanie danych

1. Załadowano plik `iris.data` (separator `;`, decimal `,`).
2. Ponumerowano przypadki 1–150.
3. Usunięto 15 przypadków (LP: 6, 16, 26, ..., 146) $\Rightarrow$ pozostało **135 przypadków**.
4. Utworzono tablicę **START** – kopia bez kolumny decyzyjnej (4 atrybuty numeryczne).

Tabela 1: Przykładowe wiersze tablicy START (pierwsze 5 przypadków)

LP	sepal_l	sepal_w	petal_l	petal_w
1	5,1	3,5	1,4	0,2
2	4,9	3,0	1,4	0,2
3	4,7	3,2	1,3	0,2
4	4,6	3,1	1,5	0,2
5	5,0	3,6	1,4	0,2

0.3 Obliczenia – szczegółowy przebieg Kroku 1

0.3.1 Środki startowe (Krok 0)

Środki pobrano z pełnego zbioru (przed usunięciem):

$$C_1 = \text{LP47} = (5,1; 3,8; 1,6; 0,2) \quad [\textit{Iris-setosa}]$$

$$C_2 = \text{LP88} = (6,3; 2,3; 4,4; 1,3) \quad [\textit{Iris-versicolor}]$$

$$C_3 = \text{LP129} = (6,4; 2,8; 5,6; 2,1) \quad [\textit{Iris-virginica}]$$

0.3.2 Miara odległości

$$d(P, C) = \sqrt{(x_1 - c_1)^2 + (x_2 - c_2)^2 + (x_3 - c_3)^2 + (x_4 - c_4)^2}$$

0.3.3 Przypisanie do klastrów – Krok 1 (wybrane przypadki)

Tabela 2: Odległości i przypisania – Krok 1 (9 wybranych przypadków)

LP	sl	sw	pl	pw	$d(C_1)$	$d(C_2)$	$d(C_3)$	Klaster
1	5,1	3,5	1,4	0,2	0,3606	3,6180	4,8405	K_1
2	4,9	3,0	1,4	0,2	0,8485	3,5581	4,8518	K_1
3	4,7	3,2	1,3	0,2	0,7810	3,7670	5,0150	K_1
50	5,0	3,3	1,4	0,2	0,5477	3,5917	4,8436	K_1
51	7,0	3,2	4,7	1,4	3,8756	1,1832	1,3491	K_2
52	6,4	3,2	4,5	1,5	3,4857	0,9327	1,3153	K_2
100	5,7	2,8	4,1	1,3	2,9698	0,8367	1,8385	K_2
101	6,3	3,3	6,0	2,5	5,1323	2,2361	0,7616	K_3
102	5,8	2,7	5,1	1,9	4,1037	1,1225	0,8124	K_3

0.3.4 Nowe środki po Kroku 1


Po przypisaniu wszystkich 135 przypadków obliczono nowe środki jako średnie arytmetyczne atrybutów w każdym klastrze:

$$C_1^{\text{new}} = (5,006; 3,428; 1,462; 0,246) \quad [45 \text{ pkt}]$$

$$C_2^{\text{new}} = (5,930; 2,752; 4,271; 1,336) \quad [44 \text{ pkt}]$$

$$C_3^{\text{new}} = (6,598; 2,978; 5,548; 2,022) \quad [46 \text{ pkt}]$$

Środki uległy zmianie $\Rightarrow$ kontynuujemy (Krok 2).



Rysunek 1: Klastry po Kroku 1 (osie: sepal_length vs petal_length). Gwiazdki = środki.

0.4 Wyniki i analiza



0.4.1 Podsumowanie iteracji

Tabela 3: Wyniki algorytmu w poszczególnych krokach



Krok	Klaster 1	Klaster 2	Klaster 3	Dokładność
1	45	44	46	94,81%
2	45	45	45	91,11%
3	45	46	44	91,85%
4	45	48	42	90,37%
5	45	49	41	89,63%
6	45	51	39	88,15%
7	45	51	39	88,15%

Algorytm zbiegł po **7 iteracjach** (Krok 7 = Krok 6, brak zmiany środków).


0.4.2 Wizualizacja iteracji



Rysunek 2: Klastry po Kroku 2 (lewo) i Kroku 3 (pravo)



Rysunek 3: Klastry po Kroku 4 (lewo) i Kroku 5 (pravo)



Rysunek 4: Klastry końcowe – Krok 7 (stan zbieżny)

0.4.3 Porównanie z oryginalnymi etykietami

Tabela 4: Macierz przypisań – stan końcowy (135 przypadków)

	Iris-setosa	Iris-versicolor	Iris-virginica
Klaster 1	45	0	0
Klaster 2	0	40	11
Klaster 3	0	5	34
Razem	45	45	45

[noitemsep]

- **Iris-setosa** (Klaster 1): $45/45 = 100\%$ – perfekcyjnie oddzielona od pozostałych gatunków (liniowo separowalna).
- **Iris-versicolor** (Klaster 2): $40/45 = 88,9\%$ – 11 próbek błędnie przypisanych do Klastra 3.
- **Iris-virginica** (Klaster 3): $34/45 = 75,6\%$ – 5 próbek błędnie przypisanych do Klastra 2.
- Ogólna dokładność: $\frac{45+40+34}{135} = 88,15\%$.

0.5 Wnioski

0.5.1 Wnioski z eksperymentu

1. Algorytm k -średnich zbiegł po **7 iteracjach**, uzyskując dokładność **88,15%** względem oryginalnych etykiet IRIS.
2. *Iris-setosa* została wydzielona **perfekcyjnie** (100%) – jej cechy (krótkie, wąskie płatki) wyraźnie odróżniają ją od pozostałych gatunków.

3. Błędy klasyfikacji dotyczą wyłącznie granicy między *Iris-versicolor* a *Iris-virginica* – gatunki te nakładają się w przestrzeni cech, co jest powszechnie znane dla tego zbioru.
4. Usunięcie 15 przypadków (co 10-ty, cyfra 6) nie wpłynęło istotnie na jakość grupowania – wynik jest porównywalny z pełnym zbiorem.

0.5.2 Zalety algorytmu k -średnich

- **Prostota i szybkość** – łatwy w implementacji, szybko zbiega dla małych zbiorów.
- **Skalowalność** – dobrze działa dla dużych zbiorów danych.
- **Interpretowalność** – środki klastrów są łatwe do interpretacji.
- **Efektywność** – złożoność $O(n \cdot k \cdot i)$, gdzie i to liczba iteracji.

0.5.3 Wady algorytmu k -średnich

- **Wymaga podania k** – liczba klastrów musi być znana z góry.
- **Wrażliwość na punkty startowe** – różne startowe środki mogą dać różne wyniki (lokalne minima).
- **Zakłada kuliste klastry** – słabo radzi sobie z klastrami o nieregularnych kształtach lub różnych gęstościach.
- **Wrażliwość na wartości odstające** – pojedynczy outlier może znacząco przesunąć środek klastra.
- **Tylko atrybuty numeryczne** – nie obsługuje bezpośrednio danych kategorycznych.

0.6 Opis problemu

Celem zadania jest wykonanie grupowania zbioru 10 punktów dwuwymiarowych (X, Y) za pomocą algorytmu k -średnich dla $k = 2$. Startowe środki dobrano zgodnie z numerem indeksu **72226**:

[noitemsep]

- **K1** – ostatnia cyfra indeksu = 6 $\Rightarrow$ LP 6 = (6, 4),
- **K2** – przedostatnia cyfra = 2 $\Rightarrow$ LP 2 = (5, 4).

Cyfry 6 i 2 są różne, więc nie stosujemy reguły $K2+1$.

0.7 Badany zbiór danych

Tabela 5: Współrzędne punktów X, Y

LP	X	Y
1	2	6
2	5	4
3	3	8
4	4	7
5	6	2
6	6	4
7	7	3
8	3	4
9	7	6
10	8	5

0.8 Obliczenia – przebieg algorytmu

0.8.1 Miara odległości

Stosowana metryka euklidesowa:

$$d(P, C) = \sqrt{(x - c_x)^2 + (y - c_y)^2}$$

0.8.2 Początkowe środki (Krok 0)

$$K_1 = \text{LP6} = (6, 4), \quad K_2 = \text{LP2} = (5, 4)$$

0.8.3 Krok 1

Środki: $K_1 = (6,0000; 4,0000)$, $K_2 = (5,0000; 4,0000)$

Tabela 6: Odległości i przypisania – Krok 1


LP	X	Y	$d(K_1)$	$d(K_2)$	Klaster
1	2	6	4,4721	3,6056	K_2
2	5	4	1,0000	0,0000	K_2
3	3	8	5,0000	4,4721	K_2
4	4	7	3,6056	3,1623	K_2
5	6	2	2,0000	2,2361	K_1
6	6	4	0,0000	1,0000	K_1
7	7	3	1,4142	2,2361	K_1
8	3	4	3,0000	2,0000	K_2
9	7	6	2,2361	2,8284	K_1
10	8	5	2,2361	3,1623	K_1

Nowe środki (średnia arytmetyczna punktów w klastrze):

$$K_1 = \left(\frac{6 + 6 + 7 + 7 + 8}{5}; \frac{2 + 4 + 3 + 6 + 5}{5} \right) = (6,8000; 4,0000)$$

$$K_2 = \left(\frac{2 + 5 + 3 + 4 + 3}{5}; \frac{6 + 4 + 8 + 7 + 4}{5} \right) = (3,4000; 5,8000)$$

Środki uległy zmianie $\Rightarrow$ kontynuujemy (Krok 2).



Rysunek 5: Klasy po Kroku 1. Gwiazdki = środki.

0.8.4 Krok 2

Środki: $K_1 = (6,8000; 4,0000)$, $K_2 = (3,4000; 5,8000)$

Tabela 7: Odległości i przypisania – Krok 2


LP	X	Y	$d(K_1)$	$d(K_2)$	Klaster
1	2	6	5,2000	1,4142	K_2
2	5	4	1,8000	2,4083	K_1
3	3	8	5,5172	2,2361	K_2
4	4	7	4,1037	1,3416	K_2
5	6	2	2,1541	4,6043	K_1
6	6	4	0,8000	3,1623	K_1
7	7	3	1,0198	4,5607	K_1
8	3	4	3,8000	1,8439	K_2
9	7	6	2,0100	3,6056	K_1
10	8	5	1,5620	4,6690	K_1

Nowe środki:

$$K_1 = \left(\frac{5 + 6 + 6 + 7 + 7 + 8}{6}; \frac{4 + 2 + 4 + 3 + 6 + 5}{6} \right) = (6,5000; 4,0000)$$

$$K_2 = \left(\frac{2 + 3 + 4 + 3}{4}; \frac{6 + 8 + 7 + 4}{4} \right) = (3,0000; 6,2500)$$

Środki uległy zmianie $\Rightarrow$ kontynuujemy (Krok 3).



Rysunek 6: Klastry po Kroku 2. Gwiazdki = środki.

0.8.5 Krok 3

Środki: $K_1 = (6,5000; 4,0000)$, $K_2 = (3,0000; 6,2500)$

Tabela 8: Odległości i przypisania – Krok 3


LP	X	Y	$d(K_1)$	$d(K_2)$	Klaster
1	2	6	4,9244	1,0308	K_2
2	5	4	1,5000	3,0104	K_1
3	3	8	5,3151	1,7500	K_2
4	4	7	3,9051	1,2500	K_2
5	6	2	2,0616	5,2022	K_1
6	6	4	0,5000	3,7500	K_1
7	7	3	1,1180	5,1539	K_1
8	3	4	3,5000	2,2500	K_2
9	7	6	2,0616	4,0078	K_1
10	8	5	1,8028	5,1539	K_1

Nowe środki:

$$K_1 = \left(\frac{5 + 6 + 6 + 7 + 7 + 8}{6}; \frac{4 + 2 + 4 + 3 + 6 + 5}{6} \right) = (6,5000; 4,0000)$$

$$K_2 = \left(\frac{2 + 3 + 4 + 3}{4}; \frac{6 + 8 + 7 + 4}{4} \right) = (3,0000; 6,2500)$$

Środki nie uległy zmianie $\Rightarrow$ algorytm zbieżny po 3 krokach.



Rysunek 7: Klastry po Kroku 3 – stan końcowy. Gwiazdki = środki.

0.9 Wyniki i analiza

Tabela 9: Ostateczne przypisanie punktów do klastrów

LP	X	Y	Klaster
1	2	6	K_2
2	5	4	K_1
3	3	8	K_2
4	4	7	K_2
5	6	2	K_1
6	6	4	K_1
7	7	3	K_1
8	3	4	K_2
9	7	6	K_1
10	8	5	K_1

Tabela 10: Podsumowanie iteracji

Krok	Środek K_1	Środek K_2	Zmiana?
Start	(6,0000; 4,0000)	(5,0000; 4,0000)	–
1	(6,8000; 4,0000)	(3,4000; 5,8000)	Tak
2	(6,5000; 4,0000)	(3,0000; 6,2500)	Tak
3	(6,5000; 4,0000)	(3,0000; 6,2500)	Nie – koniec

[noitemsep]

- **Klaster 1** (6 punktów – LP: 2, 5, 6, 7, 9, 10): środek końcowy (6,5; 4,0) – prawa dolna część przestrzeni.

- **Klaster 2** (4 punkty – LP: 1, 3, 4, 8): środek końcowy (3,0; 6,25) – lewa górna część przestrzeni.

0.10 Wnioski

1. Algorytm k -średnich ($k = 2$) zbiegł po **3 iteracjach**.
2. Punkty startowe LP6 i LP2 leżały blisko siebie ($d = 1,0$), co spowodowało duże przesunięcia środków w Kroku 1, a następnie szybką stabilizację.
3. Klaster 1 skupia punkty o wyższych X i niższych Y (prawa dolna część), Klaster 2 – punkty o niższych X i wyższych Y (lewa górna część).
4. Zmiana przypisań nastąpiła tylko raz – LP2 przeszedł z K_2 do K_1 między Krokiem 1 a Krokiem 2. Po tej zmianie klastry pozostały stabilne.
5. Metryka euklidesowa sprawdziła się dobrze – obie zmienne (X , Y) są na tej samej skali, więc żadna nie dominuje sztucznie.